

## Predicción del rendimiento de un estudiante por medio de un árbol de decisiones

|   |  |  |  |
|---|--|--|--|
| Juan Felipe Ortiz Salgado<br>Universidad Eafit<br>Colombia<br>jfortizs@eafit.edu.co | Tomas Duque Giraldo<br>Universidad Eafit<br>Colombia<br>tduqueg@eafit.edu.co | Miguel Correa<br>Universidad Eafit<br>Colombia<br>macorream@eafit.edu.co | Mauricio Toro<br>Universidad Eafit<br>Colombia<br>mtorobe@eafit.edu.co |
|---|--|--|--|

Para cada versión de este informe: 1. Detalle todo el texto en rojo. 2. Ajustar los espacios entre las palabras y los párrafos. 3. Cambiar el color de todos los textos a negro.

Texto rojo = Comentarios

Texto negro = Contribución de Miguel y Mauricio

Texto en verde = Completar para el 1er entregable

Texto en azul = Completar para el 2º entregable

Texto en violeta = Completar para el tercer entregable

### RESUMEN

El objetivo de este informe es analizar y predecir el éxito académico de un estudiante al realizar las pruebas Saber Pro. Lo que se busca es diseñar un algoritmo basado en árboles de decisión para obtener un puntaje total superior al promedio al momento de realizar las pruebas. Existen varios problemas similares al que se plantea en este informe y aunque es poco lo que se ha realizado para predecir el éxito en educación superior, algunos de estos serán analizados con el propósito de hallar una solución más efectiva.

¿Cuál es el algoritmo propuesto? ¿Qué resultados obtuvieron? ¿Cuáles son las conclusiones de este trabajo? El resumen debe tener como máximo **200 palabras**. (En este semestre, usted debe resumir aquí los tiempos de ejecución, el consumo de memoria, la exactitud, la precisión y la sensibilidad)

### Palabras clave

Árboles de decisión, aprendizaje automático, éxito académico, predicción de los resultados de los exámenes

## 1. INTRODUCCIÓN

Actualmente el papel de la tecnología es un factor clave en el proceso de la transformación digital de la educación. En el pasado, se han estudiado problemas tales como las causas y motivaciones que influyen en la deserción académica, con la cual a partir de la tecnología se han realizado algoritmos con diferentes factores que influyen en que ocurra esta. Sin

embargo, es poco lo que se ha logrado para predecir el éxito académico en educación superior.

### 1.1. Problema

El problema al cual nos enfrentamos se basa en crear a través de árboles de decisión, un algoritmo para predecir el éxito académico de las pruebas Saber pro.

### 1.2 Solución

En este trabajo, nos centramos en los árboles de decisión porque proporcionan una gran explicabilidad (¡falta una cita para este argumento!). Evitamos los métodos de caja negra como las redes neuronales, las máquinas de soporte vectorial y los bosques aleatorios porque carecen de explicabilidad (¡Falta una cita para este argumento!).

Explique, brevemente, su solución al problema (En este semestre, la solución es una implementación de un algoritmo de árbol de decisión para predecir el éxito académico. ¿Qué algoritmo elegiste? ¿Por qué?).

### 1.3 Estructura del artículo

En lo que sigue, en la sección 2, presentamos el trabajo relacionado con el problema. Más adelante, en la sección 3, presentamos los conjuntos de datos y métodos utilizados en esta investigación. En la sección 4, presentamos el diseño del algoritmo. Después, en la sección 5, presentamos los resultados. Finalmente, en la sección 6, discutimos los resultados y proponemos algunas direcciones de trabajo futuras.

## 2. TRABAJOS RELACIONADOS

Explique cuatro (4) artículos relacionados con el problema descrito en la sección 1.1. Puede encontrar los problemas relacionados en las revistas científicas. Considere el Google Scholar para su búsqueda. (En este semestre, el trabajo relacionado es la investigación de árboles de decisión para predecir los resultados de los exámenes de los estudiantes o el éxito académico)

### 3.1 Un algoritmo de árbol de decisiones relacionado con el análisis y la predicción del desempeño de los estudiantes.[1]

Se buscaba por medio un muy conocido algoritmo de minería de datos poder predecir la nota de los estudiantes de pregrado de ingeniería donde 4 árboles de decisiones fueron comparados donde después de hacer una comparación entre los cuatro se encontró que el árbol con mayor exactitud, para ser más específicos una exactitud del 80.15% fue el arbol de decisión J48, que es la versión de java del c4.5 lo que indica que este modelo es bueno para predecir las notas de los estudiantes por su gran porcentaje de exactitud.

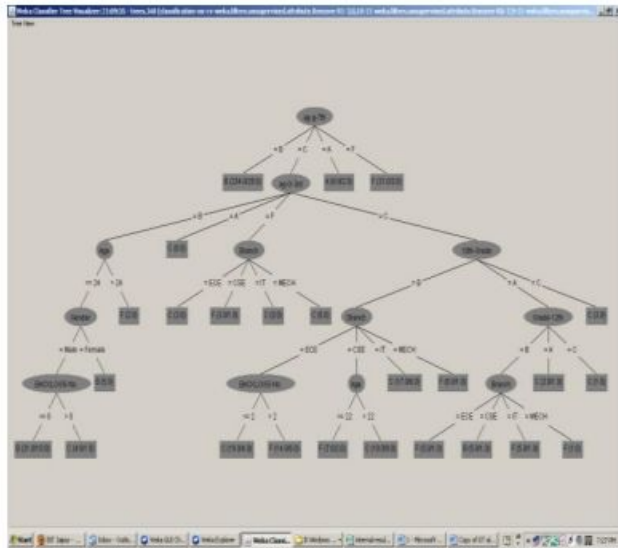
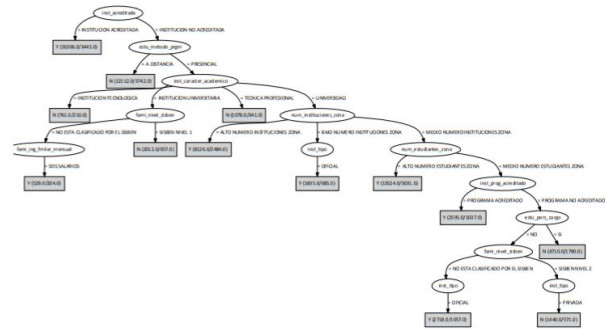


Fig 1: Decision Tree Construction

### 3.2 Un título para el segundo problema relacionado

En este caso se buscaba definir un patrón específico de desempeño académico en competencias genéricas de los estudiantes de programas profesionales. Únicamente aplicando las técnicas y algoritmos de minería de datos, que en el caso de esta investigación es clasificación por árboles de decisión.



<https://repository.ucc.edu.co/handle/20.500.12494/1039>

### 3.3 rendimiento académico.

en este se buscaron modelos predictivos y técnicas de minería de datos para la identificación de factores asociados al rendimiento académico de alumnos universitarios. Para la formulación y ajustes de los modelos de predicción, se utilizaron alternativamente, técnicas de minería de datos clásicas y métodos simbólicos o inteligentes, evaluando su desempeño en la predicción del rendimiento académico de los alumnos.

<http://sedici.unlp.edu.ar/handle/10915/19846>

### 3.4 Algoritmo para predecir tensiones con técnicas de inteligencia artificial en una tibia humana.

en este problema se buscó crear un algoritmo que permita dar solución al problema de remodelación ósea de una tibia humana bajo diferentes valores de cargas mecánicas. se utilizó el Método de los Elementos Finitos. Se usó el software profesional ABAQUS/CAE para el cálculo de tensiones y deformaciones y una red neuronal para el procesamiento de los valores obtenidos. a partir del uso de las técnicas de inteligencia artificial y con el empleo del método de los elementos finitos, fue posible obtener un modelo que pronosticó las magnitudes de tensiones.

<https://www.medigraphic.com/cgi-bin/new/resumen.cgi?IDARTICULO=63994>

## 3. MATERIALES Y MÉTODOS

En esta sección se explica cómo se recopilamos y procesamos los datos y, después, cómo se consideramos diferentes alternativas de solución para elegir un algoritmo de árbol de decisión.

### 3.1 Recopilación y procesamiento de datos

Obtuvimos datos del *Instituto Colombiano de Fomento de la Educación Superior* (ICFES), que están disponibles en línea en <ftp.icfes.gov.co>. Estos datos incluyen resultados anonimizados de Saber 11 y Saber Pro. Se obtuvieron los resultados de Saber 11 de todos los graduados de escuelas secundarias colombianas, de 2008 a 2014, y los resultados de Saber Pro de todos los graduados de pregrados colombianos, de 2012 a 2018. Hubo 864.000 registros para Saber 11 y 430.000 para Saber Pro. Tanto Saber 11 como Saber Pro, incluyeron, no sólo las puntuaciones sino también datos socioeconómicos de los estudiantes, recogidos por el ICFES, antes de la prueba.

En el siguiente paso, ambos conjuntos de datos se fusionaron usando el identificador único asignado a cada estudiante. Por lo tanto, se creó un nuevo conjunto de datos que incluía a los estudiantes que hicieron ambos exámenes estandarizados. El tamaño de este nuevo conjunto de datos es de 212.010 estudiantes. Después, la variable predictora binaria se definió de la siguiente manera: ¿El puntaje del estudiante en el Saber Pro es mayor que el promedio nacional del período en que presentó el examen?

Se descubrió que los conjuntos de datos no estaban equilibrados. Había 95.741 estudiantes por encima de la media y 101.332 por debajo de la media. Realizamos un submuestreo para equilibrar el conjunto de datos en una proporción de 50%-50%. Después del submuestreo, el conjunto final de datos tenía 191.412 estudiantes.

Por último, para analizar la eficiencia y las tasas de aprendizaje de nuestra implementación, creamos al azar subconjuntos del conjunto de datos principal, como se muestra en la Tabla 1. Cada conjunto de datos se dividió en un 70% para entrenamiento y un 30% para validación. Los conjuntos de datos están disponibles en <https://github.com/mauriciotoro/ST0245-Eafit/tree/master/proyecto/datasets>.

|                           | Conjunt<br>o de<br>datos 1 | Conjunt<br>o de<br>datos 2 | Conjunto<br>de datos<br>3 | Conjunto<br>de datos<br>4 | Conjunto<br>de datos<br>5 |
|---------------------------|----------------------------|----------------------------|---------------------------|---------------------------|---------------------------|
| <b>Entrenamient<br/>o</b> | 15,000                     | 45,000                     | 75,000                    | 105,000                   | 135,000                   |
| <b>Validación</b>         | 5,000                      | 15,000                     | 25,000                    | 35,000                    | 45,000                    |

**Tabla 1.** Número de estudiantes en cada conjunto de datos utilizados para el entrenamiento y la validación.

### 3.2 Alternativas de algoritmos de árbol de decisión

En lo que sigue, presentamos diferentes algoritmos usados para construir automáticamente un árbol de decisión binario. (En este semestre, ejemplos de tales algoritmos son ID3, C4.5 y CART).

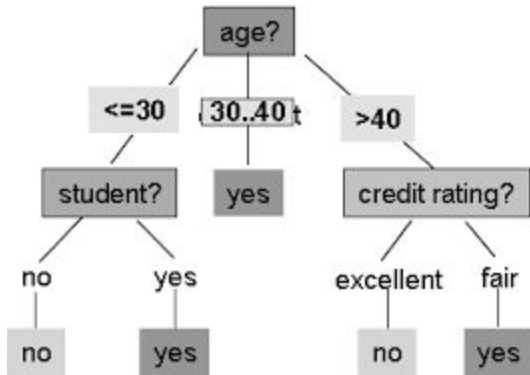
#### 3.2.1 Algoritmo ID3

Es un algoritmo inventado por Ross Quinlan que se utiliza para generar un árbol de decisiones a partir de un conjunto de datos. ID3 es el precursor del algoritmo C4.5 y normalmente se utiliza en los dominios de aprendizaje automático y procesamiento del lenguaje natural. ID3 es más difícil de usar en datos continuos que en datos factorizados.




#### 3.2.2 Algoritmo c4.5

Desarrollado a su vez por Ross es una extensión del ID3. El algoritmo C4.5 genera un árbol de decisión a partir de los datos mediante particiones realizadas recursivamente. El árbol se construye mediante la estrategia de profundidad-primero. Entre sus principales diferencias con ID3 se encuentran: Evitar Sobreajuste de los datos, determinar que tan profundo debe crecer el árbol de decisión y reducir errores.



### 3.2.3 Algoritmo Cart

El algoritmo CART es el acrónimo de Classification And Regression Trees este modelo admite variables de entrada y de salida nominales, ordinales y continuas, por lo que se pueden resolver tanto problemas de clasificación como de regresión.



## 4. DISEÑO DE LOS ALGORITMOS

En lo que sigue, explicamos la estructura de los datos y los algoritmos utilizados en este trabajo.

### 4.1 Estructura de los datos

Explique la estructura de datos utilizada para hacer la predicción y haga una figura que la explique. No utilice imágenes de Internet. (En este semestre, la estructura de datos es un árbol de decisión binario)

**Figura 1:** Un árbol de decisión binario para predecir Saber Pro basado en los resultados de Saber 11. Los nodos violetas representan a aquellos con una alta probabilidad de éxito, los verdes con una probabilidad media y los rojos con una baja probabilidad de éxito.


### 4.2 Algoritmos

Explica el diseño del algoritmo para resolver el problema y haz una figura. No uses figuras de Internet, haz las tuyas propias. (En este semestre, un algoritmo debe ser un algoritmo para entrenar un algoritmo de árbol de decisión como ID3, C4.5, CART y el segundo algoritmo debe ser un algoritmo para clasificar los nuevos datos utilizando dicho árbol).

#### 4.2.1 Entrenamiento del modelo

Explique, brevemente, cómo entrenó a la modelo: Esto equivale a explicar cómo su algoritmo construye automáticamente un árbol de decisión binario.

Figura 3. Árbol de decisión (subgrupo mujeres).

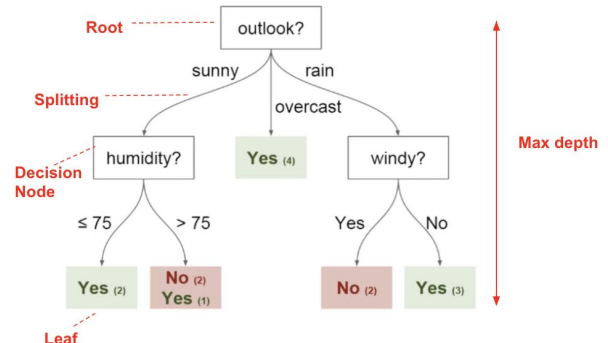


ACVA: accidente cerebrovascular agudo; FV: fibrilación ventricular; IC: insuficiencia cardíaca. En fondo gris se incluyen los nodos terminales. Los porcentajes expresan la probabilidad de mortalidad hospitalaria asignada.

### 3.2.4 Algoritmo c5.0

C5.0 es el algoritmo sucesor de C4.5, creado por la misma persona. Entre sus características se encuentran la capacidad para generar árboles de predicción simples, modelos basados en reglas y asignación de distintos pesos a los errores.

Decision Tree Diagram



**Figura 2:** Entrenamiento de un árbol de decisión binario usando *(En este semestre, uno podría ser CART, ID3, C4.5... por favor, elija)*. En este ejemplo, mostramos un modelo para predecir si se debe jugar al golf o no, según el clima.

#### 4.2.2 Algoritmo de prueba

Explique, brevemente, cómo probó el modelo: Esto equivale a explicar cómo su algoritmo clasifica los nuevos datos después de que se construya el árbol.

#### 4.3 Análisis de la complejidad de los algoritmos

Explique en sus propias palabras el análisis para el peor caso usando la notación  $O$ . ¿Cómo calculó tales complejidades.

| Algoritmo                     | La complejidad del tiempo |
|-------------------------------|---------------------------|
| Entrenar el árbol de decisión | $O(N^2 * M^2)$            |
| Validar el árbol de decisión  | $O(N^3 * M * 2N)$         |

**Tabla 2:** Complejidad temporal de los algoritmos de entrenamiento y prueba. *(Por favor, explique qué significan  $N$  y  $M$  en este problema.)*

| Algoritmo                     | Complejidad de memoria |
|-------------------------------|------------------------|
| Entrenar el árbol de decisión | $O(N * M * 2N)$        |
| Validar el árbol de decisión  | $O(1)$                 |

**Tabla 3:** Complejidad de memoria de los algoritmos de entrenamiento y prueba. *(Por favor, explique qué significan  $N$  y  $M$  en este problema.)*

#### 4.4 Criterios de diseño del algoritmo

Explica por qué el algoritmo fue diseñado de esa manera. Use un criterio objetivo. Los criterios objetivos se basan en la eficiencia, que se mide en términos de tiempo y consumo de memoria. Ejemplos de criterios no objetivos son: "Estaba enfermo", "fue la primera estructura de datos que encontré en Internet", "lo hice el último día antes del plazo", etc. Recuerde: Este es el 40% de la calificación del proyecto.

## 5. RESULTADOS

### 5.1 Evaluación del modelo

En esta sección, presentamos algunas métricas para evaluar el modelo. La precisión es la relación entre el número de

predicciones correctas y el número total de datos de entrada. Precisión. es la proporción de estudiantes exitosos identificados correctamente por el modelo y estudiantes exitosos identificados por el modelo. Por último, Sensibilidad es la proporción de estudiantes exitosos identificados correctamente por el modelo y estudiantes exitosos en el conjunto de datos.

#### 5.1.1 Evaluación del modelo en entrenamiento

A continuación presentamos las métricas de evaluación de los conjuntos de datos de entrenamiento en la Tabla 3.

|              | Conjunto de datos 1 | Conjunto de datos 2 | ...Conjunto de datos $n$ |
|--------------|---------------------|---------------------|--------------------------|
| Exactitud    | 0.7                 | 0.75                | 0.9                      |
| Precisión    | 0.7                 | 0.75                | 0.9                      |
| Sensibilidad | 0.7                 | 0.75                | 0.9                      |

**Tabla 3.** Evaluación del modelo con los conjuntos de datos de entrenamiento.

#### 5.1.2 Evaluación de los conjuntos de datos de validación

A continuación presentamos las métricas de evaluación para los conjuntos de datos de validación en la Tabla 4.

|              | Conjunto de datos 1 | Conjunto de datos 2 | ...Conjunto de datos $n$ |
|--------------|---------------------|---------------------|--------------------------|
| Exactitud    | 0.5                 | 0.55                | 0.7                      |
| Precisión    | 0.5                 | 0.55                | 0.7                      |
| Sensibilidad | 0.5                 | 0.55                | 0.8                      |

**Tabla 4.** Evaluación del modelo con los conjuntos de datos de validación.

### 5.2 Tiempos de ejecución

Calcular el tiempo de ejecución de cada conjunto de datos en Github. Medir el tiempo de ejecución 100 veces, para cada conjunto de datos, e informar del tiempo medio de ejecución para cada conjunto de datos.

|  | Conjunto de datos 1 | Conjunto de datos 2 | ...Conjunto de datos $n$ |
|--|---------------------|---------------------|--------------------------|
|--|---------------------|---------------------|--------------------------|



|                         |        |        |       |
|-------------------------|--------|--------|-------|
| Tiempo de entrenamiento | 10.2 s | 20.4 s | 5.1 s |
| Tiempo de validación    | 1.1 s  | 1.3 s  | 3.3 s |

**Tabla 5:** Tiempo de ejecución del algoritmo (*Por favor, escriba el nombre del algoritmo, C4.5, ID3*) para diferentes conjuntos de datos.

### 5.3 Consumo de memoria

Presentamos el consumo de memoria del árbol de decisión binario, para diferentes conjuntos de datos, en la Tabla 6.

|                    | Conjunto de datos 1 | Conjunto de datos 2 | ...Conjunto de datos n |
|--------------------|---------------------|---------------------|------------------------|
| Consumo de memoria | 10 MB               | 20 MB               | 5 MB                   |

**Tabla 6:** Consumo de memoria del árbol de decisión binario para diferentes conjuntos de datos.

Para medir el consumo de memoria, debería usar un generador de perfiles (*profiler*). Uno muy bueno para Java es VisualVM, desarrollado por Oracle, <http://docs.oracle.com/javase/7/docs/technotes/guides/visualvm/profiler.html>. Para Python, use C-profiler.

## 6. DISCUSIÓN DE LOS RESULTADOS

Explique los resultados obtenidos. ¿Son la precisión, exactitud y sensibilidad apropiadas para este problema? ¿El modelo está sobreajustado? ¿Es el consumo de memoria y el consumo de tiempo sib apropiados? (*En este semestre, de acuerdo con los resultados, ¿se puede aplicar esto para dar becas o para ayudar a los estudiantes con baja probabilidad de éxito? ¿Para qué es mejor?*)

### 6.1 Trabajos futuros

Respuesta, ¿qué le gustaría mejorar en el futuro? ¿Cómo le gustaría mejorar su algoritmo y su implementación? ¿Qué hay de usar un bosque aleatorio?

### AGRADECIMIENTOS

Identifique el tipo de agradecimiento que quiere escribir: Para una persona o para una institución. Considere las siguientes pautas: 1. El nombre del profesor no se menciona porque es un autor. 2. No debe mencionar sitios web de autores de artículos que no haya contactado. 3. Debe mencionar estudiantes y profesores de otros cursos que le hayan ayudado.

Como ejemplo: Esta investigación fue apoyada parcialmente por [Nombre de la Fundación, Donante].

Agradecemos la asistencia con [técnica particular, metodología] a [nombre apellido, cargo, nombre de la institución] por los comentarios que mejoraron enormemente el manuscrito.

### REFERENCIAS

La referencias se hacen con el formato de referencias de la ACM. Lea las directrices de ACM en <http://bit.ly/2pZnE5g>

A modo de ejemplo, consideremos estas dos referencias:

1. Pandey, M. y Sharma, VK (2013). Un algoritmo de árbol de decisiones relacionado con el análisis y la predicción del desempeño de los estudiantes. Revista internacional de aplicaciones informáticas, 61 (13).

2. Fischer, G. y Nakakoji, K. Amplificando la creatividad de los diseñadores con entornos de diseño orientados al dominio. en Dartnall, T. ed. Artificial Intelligence and Creativity: An Interdisciplinary Approach, Kluwer Academic Publishers, Dordrecht, 1994, 343-364.

3. Quinlan, JR 1986. Inducción de árboles de decisión. Mach. Aprender. 1, 1 (marzo de 1986), 81–106

<https://bookdown.org/content/2274/metodos-de-clasificacio-n.html>

<https://repository.ucc.edu.co/handle/20.500.12494/1039>

[https://www.medigraphic.com/cgi-bin/new/resumen.cgi?ID\\_ARTICULO=63994](https://www.medigraphic.com/cgi-bin/new/resumen.cgi?ID_ARTICULO=63994)

<http://sedici.unlp.edu.ar/handle/10915/19846>

[https://www.cienciadedatos.net/documentos/33\\_arboles\\_de\\_prediccion\\_bagging\\_random\\_forest\\_boosting](https://www.cienciadedatos.net/documentos/33_arboles_de_prediccion_bagging_random_forest_boosting)